

# Регуляризация. Гребневая регрессия. Лассо

Воробьёва Мария

- [maria.vorobyova.ser@gmail.com](mailto:maria.vorobyova.ser@gmail.com)
- @SparrowMaria

# Зачем нам регуляризация?

Переобучение может происходить по следующим причинам:

1. Данные могут быть зашумлены - модель вынуждена искать сложные закономерности на тренировочных данных
2. В данных может быть мультиколлинеарность —> задача линейной регрессии будет иметь бесконечно много решений —> на практике это может приводить к тому, что веса признаков по модулю будут сильно возрастать
3. и другие причины, такие как неправильно подобранная модель

# Зачем нам регуляризация?

Вектора  $v$  и  $x$  будут **мультиколинеарны**, если  $\langle v, x \rangle = 0$ .

Допустим, мы решаем задачу оптимизации MSE для линейной регрессии и нашли оптимальный вектор  $w$ , тогда классификаторы  $w + \alpha v$  будут давать точно такие же ответы,

что и  $w$ , так как  $\langle w + \alpha v, x \rangle = \langle w, x \rangle + \alpha \underbrace{\langle v, x \rangle}_{=0} = \langle w, x \rangle$

Это означает, что метод может найти решение с огромными коэффициентами при  $x$ , это плохо, так как классификатор будет чувствителен к крайне малым изменениям, что приведет к переобучению...




# Зачем нам регуляризация?

Существует принцип под названием «**Бритва Оккама**», который гласит:

«Сталкиваясь с двумя одинаково хорошими гипотезами,  
всегда выбирайте более простую»

# Зачем нам регуляризация?




то есть при обучении мы получили  
коэффициенты:

[0, 2022.32, 4.42, 1.31, 3156.41, 2.4, 1]

# Зачем нам регуляризация?


Будем штрафовать коэффициенты, которые слишком большие



то есть при обучении мы получили  
коэффициенты:

[0, **2022.32**, 4.42, 1.31, **3156.41**, 2.4, 1]

# Зачем нам регуляризация?



то есть при обучении мы получили  
коэффициенты:

[0, 1.5, 4.42, 1.31, 0.5, 2.4, 1]

# Линейная регрессия. Повторение

Линейная регрессия:  $a(x) = w_0 + w_1 * x_1 + w_2 * x_2 + \dots w_d * x_d$

В компактном виде 
$$a(x) = w_0 + \sum_{j=1}^d w_j x_j.$$

$w_i$  - веса/коэффициенты

$w_0$  - свободным коэффициентом/сдвиг

можно еще в **более компактном виде**  $a(x) = w_0 + \langle w, x \rangle,$

а если предположить, что существует еще один столбец со всеми 1, то можно записать

еще **компактнее**  $a(x) = \langle w, x \rangle.$



# Как штрафовать?

**Регуляризация** накладывает штраф на большие веса модели

$$Q_{\lambda}(w) = Q(w) + \lambda R(w).$$

Коэффициент  $\lambda$  - параметр регуляризации, он контролирует баланс между подгонкой под данные и штрафом за сложность

!!будем штрафовать коэффициенты только при неизвестных параметрах,  
свободный коэффициент не штрафуем

# Регуляризация L2

Регуляризация Тихонова (или Ridge regularization, или гребневая регрессия)  $R(w) = \|w\|_2 = \sum_{i=1}^d w_i^2$

$$Q(w, X) + \lambda \|w\|^2 \rightarrow \min_w.$$

$$\|y - Xw\|_2^2 + \lambda \|w\|_2^2 \rightarrow \min$$

Веса чаще всего не становятся нулевыми - они будут стремиться к 0, но не станут 0

# Регуляризация L1

Регуляризация L1 или Lasso регуляризация

$$R(w) = \|w\|_1 = \sum_{i=1}^d |w_i|$$

$$\|y - Xw\|_2^2 + \lambda \|w\|_1 \rightarrow \min$$

$$\|w\|_1 = |w_1| + |w_2| + \dots + |w_n|$$

Веса могут стать нулевыми , что полезно для задачи отбора переменных или понижения размерности

# Почему при L1 коэффициенты при регрессорах иногда зануляются?

Функция потерь (loss function)  $\text{Loss} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^m |w_j|$

Градиент 1-ого слагаемого  $\frac{\partial \text{MSE}}{\partial w_j} = -\frac{2}{N} \sum_{i=1}^N (y_i - \hat{y}_i) x_{ij}$

Градиента 2-го слагаемого  $\frac{\partial \lambda |w_j|}{\partial w_j} = \lambda \cdot \text{sign}(w_j)$

где  $\text{sign}(w_j)$  — это функция знака, которая равна 1, если  $w_j > 0$ , и -1, если  $w_j < 0$ .

Обновление весов происходит следующим образом:

$$w_j = w_j - \alpha \left( -\frac{2}{N} \sum_{i=1}^N (y_i - \hat{y}_i) x_{ij} + \lambda \cdot \text{sign}(w_j) \right)$$

Предположим, что вес  $w_j$  очень мал (например,  $w_j \approx 0.01$ ). Тогда градиент MSE может быть малым, но градиент L1 регуляризации ( $\lambda \cdot \text{sign}(w_j)$ ) будет сравнительно большим и будет пытаться уменьшить  $w_j$  ещё больше.



# Почему при L2 коэффициенты при регрессорах не зануляются?

Функция потерь (loss function)  $\text{Loss} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^m w_j^2$

Градиент 1-ого слагаемого  $\frac{\partial \text{MSE}}{\partial w_j} = -\frac{2}{N} \sum_{i=1}^N (y_i - \hat{y}_i) x_{ij}$

Градиента 2-го слагаемого  $\frac{\partial \lambda w_j^2}{\partial w_j} = 2\lambda w_j$

Обновление весов происходит следующим образом:


$$w_j = w_j - \alpha \left( -\frac{2}{N} \sum_{i=1}^N (y_i - \hat{y}_i) x_{ij} + 2\lambda w_j \right)$$

L2 регуляризация стремится уменьшить значения весов, но не "притягивает" их к нулю так же агрессивно, как это делает L1 регуляризация. Поскольку штраф в L2 регуляризации пропорционален квадрату веса, он становится меньше по мере уменьшения веса. Таким образом, когда вес становится малым, влияние регуляризационного члена также уменьшается, и вес стремится к малым значениям, но не становится нулевым.



# Ridge регрессия

$$y = \omega_1 x + \omega_0$$




$$Q(w, X) = (Xw - y)^2 \rightarrow \min$$

$$\omega_1^2 + \omega_0^2 \leq c$$



# LASSO регрессия

$$y = \omega_1 x + \omega_0$$



$$Q(w, X) = (Xw - y)^2 \rightarrow \min \quad |\omega_1| + |\omega_0| \leq t$$

# Регуляризация

$$L(f(x, \omega), y) = \sum_{i=1}^M \left( y_i - \sum_{j=0}^p \omega_j x_{ij} \right)^2 + \lambda \sum_{j=0}^p |\omega_j|$$

LASSO регрессия

$$L(f(x, \omega), y) = \sum_{i=1}^M \left( y_i - \sum_{j=0}^p \omega_j x_{ij} \right)^2 + \lambda \sum_{j=0}^p \omega_j^2$$

RIDGE регрессия


$$L(f(x, \omega), y) = \sum_{i=1}^M \left( y_i - \sum_{j=0}^p \omega_j x_{ij} \right)^2 + \lambda_1 \sum_{j=0}^p \omega_j^2 + \lambda_2 \sum_{j=0}^p |\omega_j|$$

ElasticNet регрессия




# ElasticNet регрессия

$$y = \omega_1 x + \omega_0$$




ElasticNet  
оценка

$$\omega_1^2 + \omega_0^2 + |\omega_1| + |\omega_0| \leq c$$



минимум  
квадратичной  
ошибки





# Регуляризация

## `sklearn.linear_model.Lasso`

```
class sklearn.linear_model.Lasso(alpha=1.0, *, fit_intercept=True, precompute=False, copy_X=True, max_iter=1000, tol=0.0001, warm_start=False, positive=False, random_state=None, selection='cyclic')
```

[\[source\]](#)

## `sklearn.linear_model.Ridge`

```
class sklearn.linear_model.Ridge(alpha=1.0, *, fit_intercept=True, copy_X=True, max_iter=None, tol=0.0001, solver='auto', positive=False, random_state=None)
```

[\[source\]](#)

## `sklearn.linear_model.ElasticNet`

```
class sklearn.linear_model.ElasticNet(alpha=1.0, *, l1_ratio=0.5, fit_intercept=True, precompute=False, max_iter=1000, copy_X=True, tol=0.0001, warm_start=False, positive=False, random_state=None, selection='cyclic')
```

[\[source\]](#)



# Регуляризация

## `sklearn.linear_model.LogisticRegression`

```
class sklearn.linear_model.LogisticRegression(penalty='l2', *, dual=False, tol=0.0001, C=1.0, fit_intercept=True,
intercept_scaling=1, class_weight=None, random_state=None, solver='lbfgs', max_iter=100, multi_class='auto', verbose=0,
warm_start=False, n_jobs=None, l1_ratio=None)
```

[\[source\]](#)

**Warning:** The choice of the algorithm depends on the penalty chosen: Supported penalties by solver:

- 'newton-cg' - ['l2', 'none']
- 'lbfgs' - ['l2', 'none']
- 'liblinear' - ['l1', 'l2']
- 'sag' - ['l2', 'none']
- 'saga' - ['elasticnet', 'l1', 'l2', 'none']





УНИВЕРСИТЕТ  
ИННОПОЛИС

# ВОПРОСЫ И ОТВЕТЫ